

Sprint 3

Índice

Nivel 1-----	2
Ejercicio 1-----	2
Ejercicio 2-----	6
Ejercicio 3-----	7
Ejercicio 4-----	8
Ejercicio 5-----	12
Ejercicio 6-----	13
Nivel 2-----	14
Ejercicio 1-----	14
Ejercicio 2-----	15
Ejercicio 3-----	16
Ejercicio 4-----	17

Nivel 1

Acabas de llegar a la empresa. El equipo de Ingeniería de Datos ha dejado los archivos históricos en el Data Lake corporativo.

Tu primera misión es diseñar y crear el entorno de trabajo. El CTO exige profesionalidad: no volcaremos datos sin orden, sino que implementaremos una Arquitectura Medallion.

Ejercicio 1

Implementarás físicamente la arquitectura lógica creando tres Datasets dentro de un mismo proyecto para centralizar la facturación y los permisos.

Crea un Nuevo Proyecto en Google Cloud llamado:

sprint3-analytics-[tu-nombre]



Puedes crearlo por la UI, pero si lo haces por Consola (gcloud CLI) tiene un plus.

```
gcloud projects create sprint3-analytics-alejandro[
```

Notificaciones



Crear proyecto: sprint3-analytics-alejandro hace 6 días

[Seleccionar proyecto](#)


Para demostrar tu dominio total de la plataforma, crearás cada uno de los datasets utilizando un método distinto:

- ➡ Dataset Físico *sprint3_bronze* → Capa Lógica Bronce (Datos Crudos)
 - ➡ Función: Datos crudos tal y como llegan de la fuente.
 - ➡ Método: Utiliza la **Interfaz Gráfica (UI)** de BigQuery (haciendo clics).

The screenshot shows the Google Cloud BigQuery console interface. On the left, a sidebar lists navigation options: 'Conjuntos de datos' (Datasets), 'Conexiones' (Connections), and 'Conversaciones' (Conversations). The main area displays a modal dialog titled 'Crear un conjunto de datos' (Create a dataset). The dialog contains the following fields and options:

- ID del proyecto ***: sprint3-analytics-alejandro (with a 'Cambiar' button).
- ID de conjunto de datos ***: sprint3_bronze (with a note: 'Puede incluir letras, números y guiones bajos').
- Ubicación de los datos**: europe-southwest1 (Madrid) (with a dropdown arrow and a help icon).
- Conjunto de datos externo**: The selected region supports the following external dataset types: Cloud Spanner. There is an unchecked checkbox for 'Vínculo a un conjunto de datos externo' (Link to an external dataset).
- Etiquetas**: A section with a dropdown arrow.
- Opciones avanzadas**: A section with a dropdown arrow.
- At the bottom, there are two buttons: 'Crear conjunto de datos' (Create dataset) and 'Cancelar' (Cancel).


- ➔ Dataset Físico *sprint3_silver* → Capa Lógica Silver (Datos Limpios)
 - ➔ Función: Datos limpios, tipados y duplicados.
 - ➔ Método: Utiliza **código SQL** (CREATE SCHEMA).



The screenshot shows a SQL editor window with a dark theme. The title bar indicates an open file named '*Consult...ulo'. The main area displays a SQL query to create a schema. The query is as follows:


```
1 CREATE SCHEMA `sprint3-analytics-alejandro.sprint3_silver`  
2 OPTIONS (  
3   location = 'europe-southwest1'  
4 );  
5
```

At the top of the editor, there are buttons for 'Ejecutar' (Execute), 'Guardar' (Save), and 'Descargar' (Download).



The screenshot shows the results of the SQL query. At the top, a green checkmark and the text 'Se completó la consulta' (Query completed) indicate success. Below this, the title 'Resultados de la consulta' is followed by tabs for 'Chat', 'Guardar los resultados' (Save results), and 'Abrir en' (Open in). A sub-header 'Información del trabajo' (Job information) is followed by tabs for 'Resultados' (Results), 'Detalles de la ejecución' (Execution details), and 'Gráfico de ejecución' (Execution graph). The main content area shows a message: 'Se creó el conjunto de datos llamado sprint3_silver.' (The data set named sprint3_silver was created.) A button labeled 'Ir al conjunto de datos' (Go to data set) is located at the bottom right.

- ➔ Dataset Físico *sprint3_gold* → Capa Lógica Gold (Datos de Negocio)
 - ➔ Función: Datos agregados listos para informes y paneles de control (dashboards).
 - ➔ Método: Utiliza **Cloud Shell** (Línea de comandos bq).



```
CLOUD SHELL
Terminal (sprint3-analytics-alejandro) x + v
Gemini CLI está disponible en la terminal de Cloud Shell. Pruébala escribiendo gemini. Más información

Welcome to Cloud Shell! Type "help" to get started, or type "gemini" to try prompting with Gemini CLI.
Your Cloud Platform project in this session is set to sprint3-analytics-alejandro.
Use 'gcloud config set project [PROJECT_ID]' to change to a different project.
alejandroapg04@cloudshell:~ (sprint3-analytics-alejandro)$ bq --location=europe-southwest1 mk -d sprint3-analytics-alejandro:sprint3_gold
Dataset 'sprint3-analytics-alejandro:sprint3_gold' successfully created.
alejandroapg04@cloudshell:~ (sprint3-analytics-alejandro)$
```

Ten en cuenta la ubicación de los datos originales para decidir la ubicación física de los tres Datasets.

! Nota: Aunque sean capas lógicas diferentes, físicamente deben vivir en la misma región para poder "hablar" entre ellas sin costes de transferencia.

Ejercicio 2

Escribe y ejecuta las sentencias CREATE EXTERNAL TABLE para conectar los siguientes archivos al dataset *sprint3_bronze*. Presta mucha atención a las "Notas Técnicas", ya que no todos los archivos tienen el mismo formato.

Tabla	Dominio	Ruta a la Nube (URI)	Notas Técnicas
transactions_raw	ERP	gs://bootcamp-data-analytics-public/ERP/transactions.csv	Delimitador: ; (Punto y coma)
companies_raw	ERP	gs://bootcamp-data-analytics-public/ERP/companies.csv	Cabecera: Ignora 1a fila. Define el esquema manualmente porque todo es texto.
american_users_raw	CRM	gs://bootcamp-data-analytics-public/CRM/american_users.csv	Estándar.
european_users_raw	CRM	gs://bootcamp-data-analytics-public/CRM/european_users.csv	Estándar.
credit_cards_raw	CRM	gs://bootcamp-data-analytics-public/CRM/credit_cards.csv	Estándar.

El código SQL utilizado para *transactions_raw* y una captura de pantalla con las 5 tablas creadas.

```

1 CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.transactions_raw`
2 OPTIONS (
3   format = "CSV",
4   uri = ['gs://bootcamp-data-analytics-public/ERP/transactions.csv'],
5   field_delimiter = ';'
6 );
7 CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.companies_raw`
8 (
9   company_id STRING,
10  company_name STRING,
11  phone STRING,
12  email STRING,
13  country STRING,
14  website STRING
15 );
16 OPTIONS (
17   format = "CSV",
18   uri = ['gs://bootcamp-data-analytics-public/ERP/companies.csv'],
19   skip_leading_rows = 1
20 );
21 CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.american_users_raw`
22 OPTIONS (
23   format = "CSV",
24   uri = ['gs://bootcamp-data-analytics-public/CRM/american_users.csv']
25 );
26 CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.european_users_raw`
27 OPTIONS (
28   format = "CSV",
29   uri = ['gs://bootcamp-data-analytics-public/CRM/european_users.csv']
30 );
31 CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.credit_cards_raw`
32 OPTIONS (
33   format = "CSV",
34   uri = ['gs://bootcamp-data-analytics-public/CRM/credit_cards.csv']
35 );
36
37

```

Estado	Hora de finalización	SQL	Etapas finalizadas	Bytes procesados	Acción
✓	11:10a.m. [1:1]	CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.transactions_raw`	0	0 B	Ver resultados
✓	11:10a.m. [7:1]	CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.companies_raw`	0	0 B	Ver resultados
✓	11:10a.m. [21:1]	CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.american_users_raw`	0	0 B	Ver resultados
✓	11:11a.m. [26:1]	CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.european_users_raw`	0	0 B	Ver resultados
✓	11:11a.m. [31:1]	CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alejandro.sprint3_bronze.credit_cards_raw`	0	0 B	Ver resultados

Ejercicio 3

Falta el catálogo de Productos. Esta información no está en Data Lake, utiliza el archivo *products.csv* del sprint 2.

- ➔ Carga este archivo manualmente ("Upload") en el dataset *sprint3_bronze* y crea la tabla *products_raw*.
- ➔ Observa que esta será la única Table Nativa de momento.

Explorador

+ Agregar datos



Local File

Transferencia de datos desde archivos locales.

Crear tabla

Fuente

Create table from
Subir

Seleccionar archivo *

N1-Ex.8_products.csv

Formato del archivo

CSV

Destino

Proyecto *

sprint3-analytics-alejandro

Conjunto de datos *

sprint3_bronze

Tabla *

products_raw

El tamaño máximo del nombre es de 1,024 bytes UTF-8. Se permiten letras, signos, números, conectores, guiones y espacios Unicode.

Tipo de tabla

Tabla nativa

Esquema

☒ Detección automática

El esquema se generará automáticamente.

Configuración de partición

☒ Sin particionar

☐ Particionar por tiempo de transferencia

☐ Particionar por campo

Para particionar por campo, primero debes agregar campos al esquema anterior.

Configuración del clúster

Orden del anidamiento en clústeres

Crear tabla Cancelar

Se creó "products_raw". Ir a la tabla

Ejercicio 4

Las consultas sobre el Data Lake van lentas. Tienes que demostrar a tu manager la diferencia de rendimiento entre trabajar con archivos externos y trabajar con tablas nativas de BigQuery.

a) Materialización de Datos (Asistido por IA)

Crea una tabla nueva llamada *sprint3_bronze.transactions_raw_native* que sea una copia exacta de tu tabla externa *transactions_raw*.



Requisito de "AI-Pair Programming":

No escribas el código SQL manualmente. Utiliza el Asistente de IA (Gemini) integrado en BigQuery (o el chat lateral) para generar la sentencia.



Tu Rol: Eres el responsable de validar que el código que te da la IA es correcto antes de ejecutarlo.

Prompt Sugerido:

"Write a SQL query to create a new table called *transactions_raw_native* in the *sprint3_bronze* dataset. It should contain all data from the *transactions_raw* table. Please use `CREATE OR REPLACE TABLE` so I don't get errors if I run it more than once."

Capturas de pantalla:

- ➔ El prompt que escribiste en la IA.
- ➔ El código SQL que la IA va a generar.
- ➔ El resultado de la ejecución ("This statement created a new table...").



b) Auditoría de Costes

Diseñar una prueba para comparar el coste de leer una sola columna (ej: id) en la tabla externa vs. la tabla nativa. Utiliza los Bytes procesados y los Bytes facturados para realizar la comparación.

➡ ¿Cuánto pesa la consulta en *transactions_raw*?

```
8 SELECT id
9 FROM `sprint3-analytics-alejandro.sprint3_bronze.transactions_raw`;
10
11 SELECT id
12 FROM `sprint3-analytics-alejandro.sprint3_bronze.transactions_raw_native`;
```

✓ Esta consulta procesará 0 B cuando se ejecute.

➡ ¿Cuánto pesa la misma consulta en *transactions_raw_native*?

```
7 SELECT id
8 FROM `sprint3-analytics-alejandro.sprint3_bronze.transactions_raw`;
9
10 SELECT id
11 FROM `sprint3-analytics-alejandro.sprint3_bronze.transactions_raw_native`;
```

✓ Esta consulta procesará 3.62 MB cuando se ejecute.

Conclusión técnica: La tabla nativa guarda los datos en el almacenamiento de BigQuery, ocupando espacio. Por otro lado, la tabla externa hace referencia a datos guardados fuera de BigQuery, por lo que no se usa el almacenamiento de este.

c) El peligro del LIMIT

Muchos analistas piensan que poner LIMIT 10 reduce el coste de la consulta.

Haz un `SELECT * FROM transactions_raw_native LIMIT 10` sobre la tabla externa.

- ✓ Comprobación:
Mira el "Dry Run". ¿Ha bajado el coste respecto a no poner LIMIT? Explica brevemente por qué esto es una trampa para principiantes.

```
14 SELECT * FROM sprint3_bronze.transactions_raw_native LIMIT 10;  
15 SELECT * FROM sprint3_bronze.transactions_raw_native;
```

✓ Esta consulta procesará 10.87 MB cuando se ejecute.

```
14 SELECT * FROM sprint3_bronze.transactions_raw_native LIMIT 10;  
15 SELECT * FROM sprint3_bronze.transactions_raw_native;
```

✓ Esta consulta procesará 10.87 MB cuando se ejecute.

Añadir un LIMIT a la consulta no implica haber consultado únicamente 10 resultados. Lo que hace LIMIT es filtrar los 10 primeros resultados tras haberlos consultado todos.

Ejercicio 5

Tu jefe quiere saber cuáles fueron los 5 días con mayores ingresos del año 2021.

Probablemente el campo timestamp sea un STRING. Tendrás que investigar funciones de BigQuery (SUBSTR, CAST, PARSE_TIMESTAMP) para filtrar el año y agruparlo por fecha correctamente.

```
1 SELECT ROUND(SUM(amount),2) AS ingresos, DATE(timestamp) AS fecha
2 FROM `sprint3_bronze.transactions_raw`
3 WHERE EXTRACT(YEAR FROM DATE(timestamp)) = 2021
4 GROUP BY DATE(timestamp)
5 ORDER BY ingresos DESC
6 LIMIT 5
7 ;
```

✓ Esta consulta procesará 0 B cuando se ejecute.

Resultados de la consulta

Información del trabajo **Resultados** Visualización JSON Detalles de la

i El almacenamiento en caché de metadatos está inhabilitado. Puedes acelerar las consulta

Fila	ingresos	fecha
1	11440.81	2021-10-27
2	11328.84	2021-01-22
3	11182.16	2021-02-11
4	11119.01	2021-04-29
5	10898.51	2021-03-27

Ejercicio 6

Necesitamos un informe que cruce datos.

Lista el nombre, país y fecha de las transacciones realizadas por empresas que realizaron operaciones entre 100 y 200 euros en alguna de estas fechas: 29-04-2015, 20-07-2018 o 13-03-2024.

```
1 SELECT company_name, country, timestamp
2 FROM 'sprint3_bronze.transactions_raw'
3 JOIN 'sprint3_bronze.companies_raw'
4   ON 'sprint3_bronze.transactions_raw'.business_id = 'sprint3_bronze.companies_raw'.company_id
5 WHERE amount BETWEEN 100 AND 200 AND DATE(timestamp) IN ('2015-04-29', '2018-07-20', '2024-03-13');
```

Resultados de la consulta

Chat Guardar los resultados Abrir en

Información del trabajo Resultados Visualización JSON Detalles de la ejecución Gráfico de ejecución

El almacenamiento en caché de metadatos está inhabilitado. Puedes acelerar las consultas en tablas externas habilitando el almacenamiento en caché de metadatos. [Más información](#) Dismiss

Fila	company_name	country	timestamp
1	At Pede Corp.	Italy	2018-07-20 07:49:29 UTC
2	Fusce Corp.	United States	2018-07-20 02:40:13 UTC
3	Magna Incorporated	New Zealand	2018-07-20 07:41:52 UTC
4	Et Magnis Ltd	Belgium	2018-07-20 23:32:19 UTC
5	Ac Libero Inc.	United Kingdom	2024-03-13 14:03:13 UTC
6	Donec Fringilla PC	France	2015-04-29 06:37:02 UTC
7	Amet Lorem LLP	Spain	2015-04-29 14:24:51 UTC
8	Netus Et Malesuada Ltd	Netherlands	2018-07-20 00:32:35 UTC
9	Ac Libero Inc.	United Kingdom	2015-04-29 13:53:21 UTC
10	Justo Eu Arcu Ltd	Italy	2018-07-20 11:30:50 UTC


Nivel 2

Los datos brutos tienen problemas de calidad (símbolos de moneda, usuarios duplicados, fechas incorrectas). Actúa como Data Engineer para limpiarlo todo.


Ejercicio 1

Crearemos la capa limpia ("Silver") para los productos. Tienes la tabla *sprint3_bronze.products_raw* cargada desde el CSV. El equipo de Data Governance te pide crear una tabla de productos limpia en *sprint3_silver.products_clean* que cumpla estas reglas de calidad:

- ➔ Estandarización de Nombres: La columna original id es ambigua; renombrarla a *product_id*. La columna *product_name* simplifícala a *name*.
- ➔ Limpieza de IDs: El campo *warehouse_id* tiene el formato antiguo "WH-4". Elimina el prefijo "WH-" y convierte el valor en número entero (INT64).
- ➔ Garantía de Precio: Asegúrate de que *price* es un número (FLOAT64), sin símbolos de moneda.
- ➔ Otras columnas: Conserva el campo *weight* (peso) tal cual.



```
1 CREATE OR REPLACE TABLE sprint3_silver.products_clean AS
2 SELECT id AS product_id,
3        product_name AS name,
4        SAFE_CAST(REPLACE(warehouse_id, 'WH-', '') AS INT64) AS warehouse_id,
5        SAFE_CAST(REGEXP_REPLACE(CAST(price AS STRING), r'^\d-\d.\d', '') AS FLOAT64) AS price,
6        weight
7 FROM sprint3_bronze.products_raw;
```




Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

i Esta declaración creó una nueva tabla con el nombre *products_clean*.

Ejercicio 2

La tabla *transactions_raw* (Bronze) es insegura: el importe (amount) podría tener letras, las coordenadas podrían fallar y la fecha es un texto difícil de filtrar. Crearemos la tabla definitiva *sprint3_silver.transactions_clean* que garantice lo siguiente.

- ➔ Estandarización de Nombres: La columna original *id* es ambigua; renombrarla a *transaction_id*.
- ➔ Robustez en Importes: Utiliza *SAFE_CAST* en el campo *amount*. Si falla, sustitúyelo por 0 (usando *IFNULL*).
- ➔ Fechas Reales: Convierte el campo *timestamp* (que es *STRING*) a tipo *TIMESTAMP* real.
- ➔ Coordenadas: Asegura que *lat* y *longitud* sean *FLOAT64* (utiliza *SAFE_CAST* para seguridad).
- ➔ Desglose de Productos: Transforma la cadena de texto *product_ids* en un *ARRAY* de enteros.
Input: "1, 2, 3" (String)
Output: [1, 2, 3] (Array/Lista de enteros)
- ➔ Resto de campos: Manténlos igual.



```
1 CREATE OR REPLACE TABLE sprint3_silver.transactions_clean AS
2 SELECT id AS transaction_id,
3        IFNULL(SAFE_CAST(amount AS FLOAT64), 0) AS amount,
4        SAFE_CAST(timestamp AS TIMESTAMP) AS transaction_timestamp,
5        SAFE_CAST(lat AS FLOAT64) AS lat,
6        SAFE_CAST(longitude AS FLOAT64) AS longitude,
7        ARRAY(
8          SELECT SAFE_CAST(TRIM(id) AS INT64)
9          FROM UNNEST(SPLIT(product_ids, ',')) AS id
10         WHERE SAFE_CAST(TRIM(id) AS INT64) IS NOT NULL
11        ) AS product_ids_array,
12        user_id,
13        card_id,
14        business_id,
15        declined,
16
17 FROM sprint3_bronze.transactions_raw;
```

Se completó la consulta

Resultados de la consulta

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

Esta declaración creó una nueva tabla con el nombre *transactions_clean*.

Ejercicio 3

Tenemos a los usuarios fragmentados por región.

Crea la tabla `sprint3_silver.users_combined`. Utiliza `UNION ALL` para unificar a los usuarios de EE.UU. y Europa en una única lista maestra. Añade una columna calculada `origin` para saber de dónde vienen.

➔ Estandarización de Nombres: La columna original `id` es ambigua; renombrarla a `user_id`.

```
1 CREATE OR REPLACE TABLE `sprint3_silver.users_combined` AS
2 SELECT id AS user_id,
3     name,
4     surname,
5     email,
6     phone,
7     birth_date,
8     country,
9     city,
10    postal_code,
11    address,
12    'Europe' AS origin
13 FROM `sprint3_bronze.european_users_raw`
14
15 UNION ALL
16
17 SELECT id AS user_id,
18     name,
19     surname,
20     email,
21     phone,
22     birth_date,
23     country,
24     city,
25     postal_code,
26     address,
27     'America' AS origin
28 FROM `sprint3_bronze.american_users_raw`
29
30
```

✓ Se completó la consulta

Resultados de la consulta

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución


i Esta declaración creó una nueva tabla con el nombre `users_combined`.

Ejercicio 4

Para completar el modelo de datos en la capa Silver, nos faltan dos dimensiones clave que actualmente dependen de archivos CSV externos: Compañías y Tarjetas de Crédito. No podemos depender de archivos sueltos para el análisis final. Debemos importar estos datos en tablas nativas (Silver) y aprovechar para corregir formatos.

- ➔ Crea la tabla `sprint3_silver.companies_clean`. Copia los datos tal cual, pero asegúrate de que sea una tabla nativa de BigQuery (no una vista externa).
- ➔ Crea la tabla `sprint3_silver.credit_cards_clean`. Copia los datos tal cual, pero asegúrate de que sea una tabla nativa de BigQuery (no una vista externa).

Si es necesario, renombrar el id según corresponda.



The screenshot displays a BigQuery console interface. At the top, two SQL queries are entered in a dark-themed editor. The first query creates a table named `sprint3-analytics-alejandro.sprint3_silver.companies_clean` by selecting columns from `sprint3-bronze.companies_raw`. The second query creates a table named `sprint3-analytics-alejandro.sprint3_silver.credit_cards_clean` by selecting columns from `sprint3-bronze.credit_cards_raw`. Below the editor, a status bar indicates 'Se completó la consulta' (Query completed). Under 'Todos los resultados' (All results), a summary shows 'Tiempo transcurrido' (3 s), 'Declaraciones procesadas' (2), and 'Estado del trabajo' (SUCCESS). A table at the bottom lists the execution details for both queries, including their state, completion time, SQL text, number of stages, bytes processed, and a link to view results.

Estado	Hora de finalización	SQL	Etapas finalizadas	Bytes procesados	Acción
✓	11:02a.m. [1:1]	CREATE OR REPLACE TABLE 'sprint3-analytics-alejandro.sprint3_silver.companies_clean' AS	3	10.1 KB	Ver resultados
✓	11:02a.m. [1:1]	CREATE OR REPLACE TABLE 'sprint3-analytics-alejandro.sprint3_silver.credit_cards_clean' AS	3	804.85 KB	Ver resultados